




클라우드 기반 데이터레이크 및 분석

Data Lake는 어떻게 구축해야 하는가?





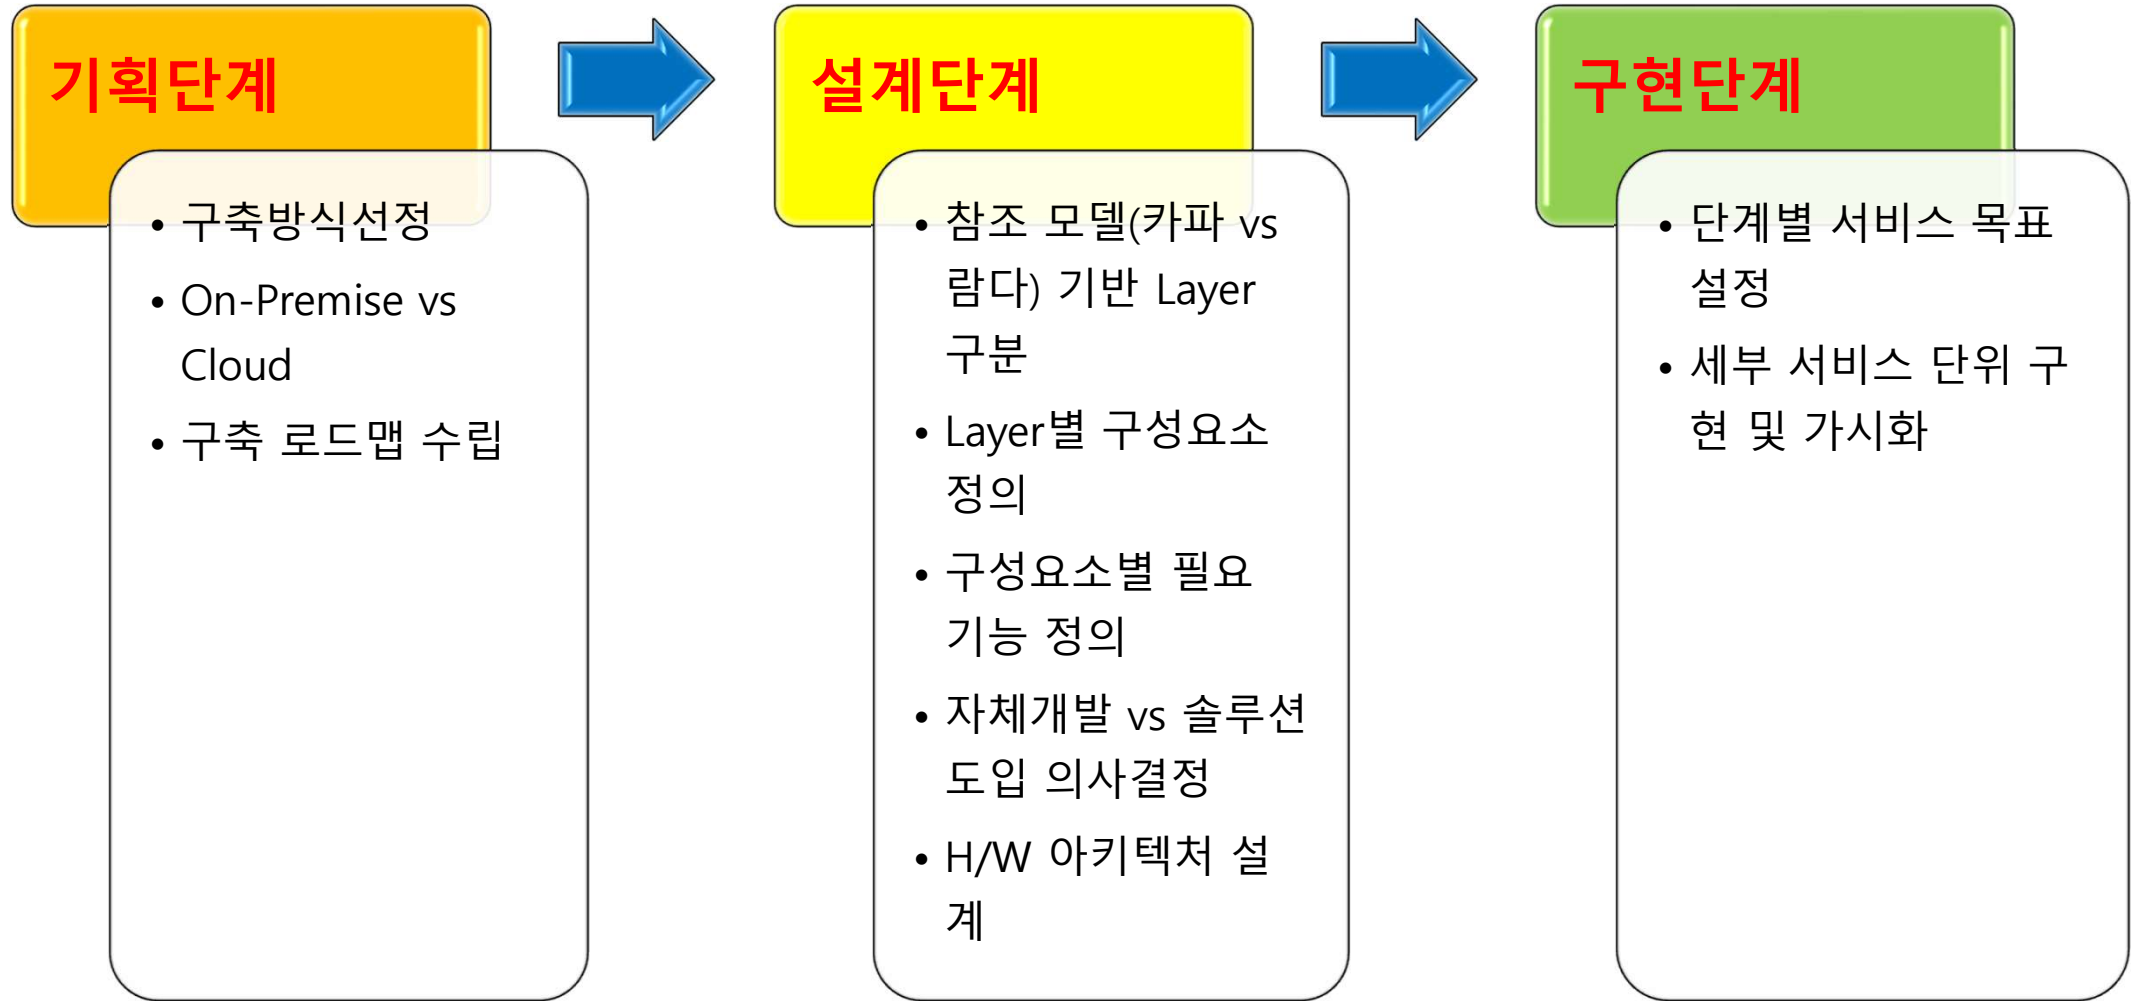
Index

- 01. Data Lake 구현 방식
- 02. Data Lake 구축 로드맵
- 03. Building Data Lake on AWS
- 04. Apache Spark 소개

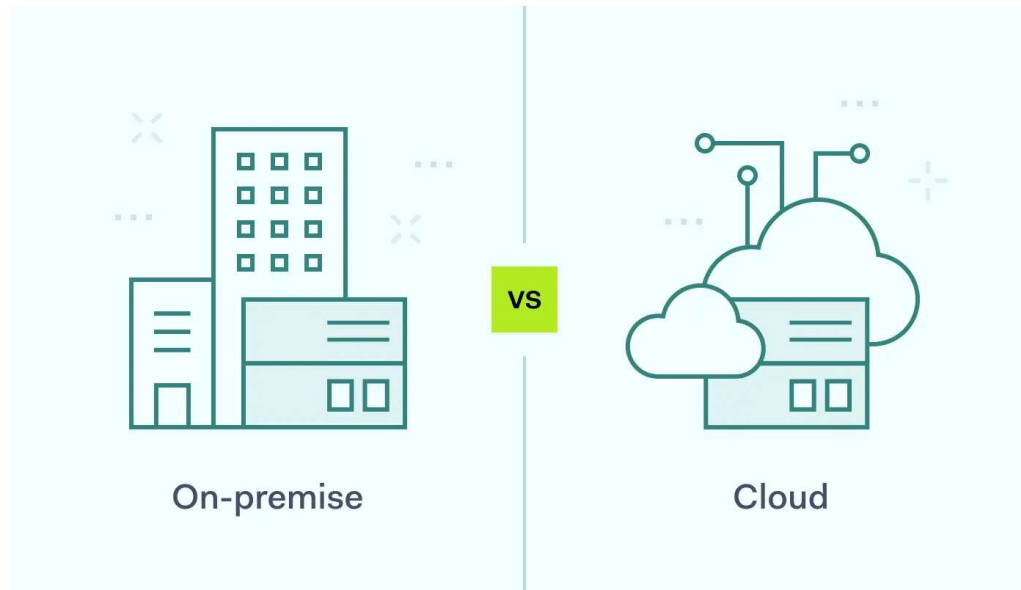
Data Lake 구현 방식



Data Lake 구현 단계




On-Premise vs. Cloud



- 리소스 소요 변동 폭이 적을 시 유리
- 실시간 처리 비중이 높을 시 유리
- 향후 확장 가능성 적을 경우 유리
- 전사 공통 비용 기반으로 운영 시 유리
- 자사의 데이터 센터에 모두 구성

- 리소스 소요 변동 폭이 클 경우 유리
- 배치성 업무 처리 비중이 높을 시 유리
- 향후 확장 가능성 높을 경우 유리
- 조직별 사용량에 따른 비용 배분 시 유리
- private, public, hybrid

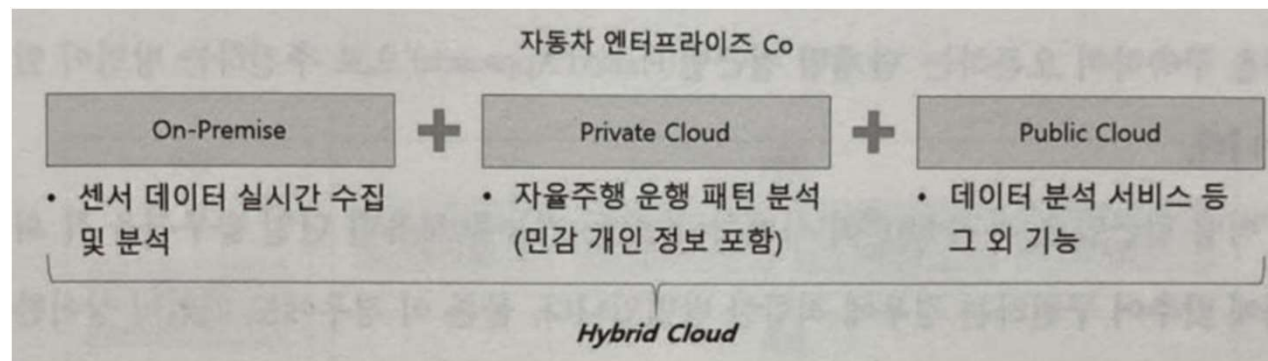
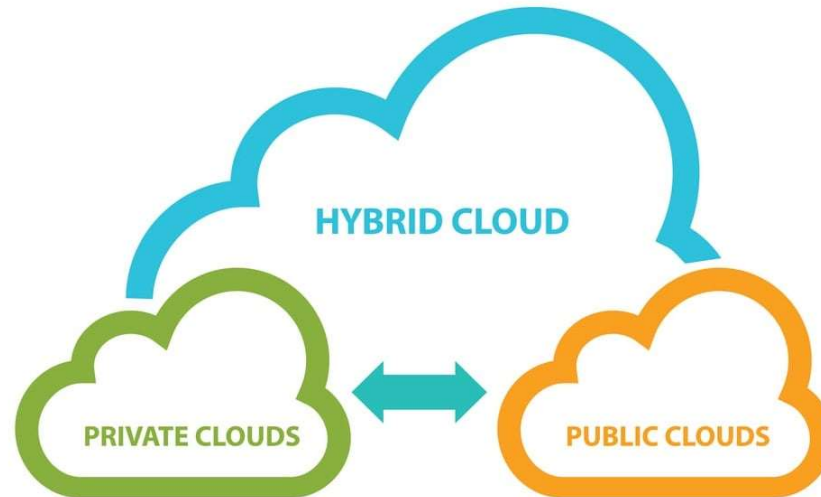
Private Cloud vs. Public Cloud



- 엄격한 데이터 보안 규제/정책 존재
- 구성원의 충분한 구현 역량/비용 보유
- 장기간에 단계별로 기능 구현 시
- Cloud 서비스의 자사 핵심 역량화
- 필요한 서비스가 외부 벤더에 없을 시
- 급격한 리소스 수요 변동 적을 시

- 민감 데이터 보안, 규제 이슈 적을 시
- 자사의 IT 구현 역량 충분하지 못할 시
- 단기간에 적은 비용으로 구현 필요 시
- 단순히 Cloud 서비스를 이용
- 필요한 서비스를 외부에서 조달 가능 시
- 급격한 리소스 수요 변동 존재

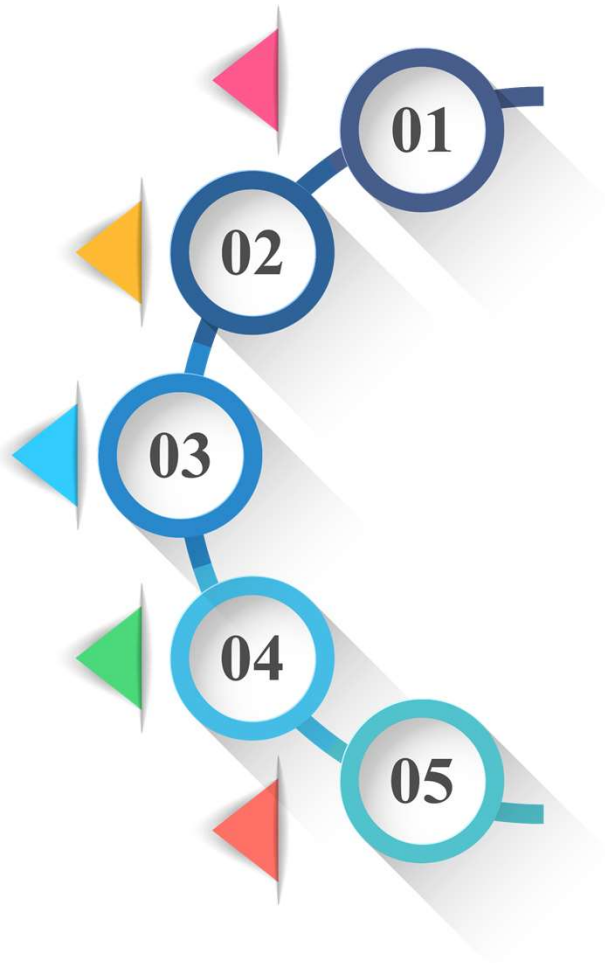
Hybrid Cloud



Data Lake 구축 로드맵




Data Lake 구축 로드맵



- Data Lake 구축은 장기간 소요되는 전사적 전환 과제
- 빅뱅 접근법(Big Bang Approach)
 - 모든 기능을 보유한 단일 솔루션을 각 회사에 맞추어 구현
- 단계별 접근법(Phased Approach)
 - 단계별로 기능을 구축하여 오픈

Hadoop 기반 솔루션 vs. Cloud 솔루션

hadoop

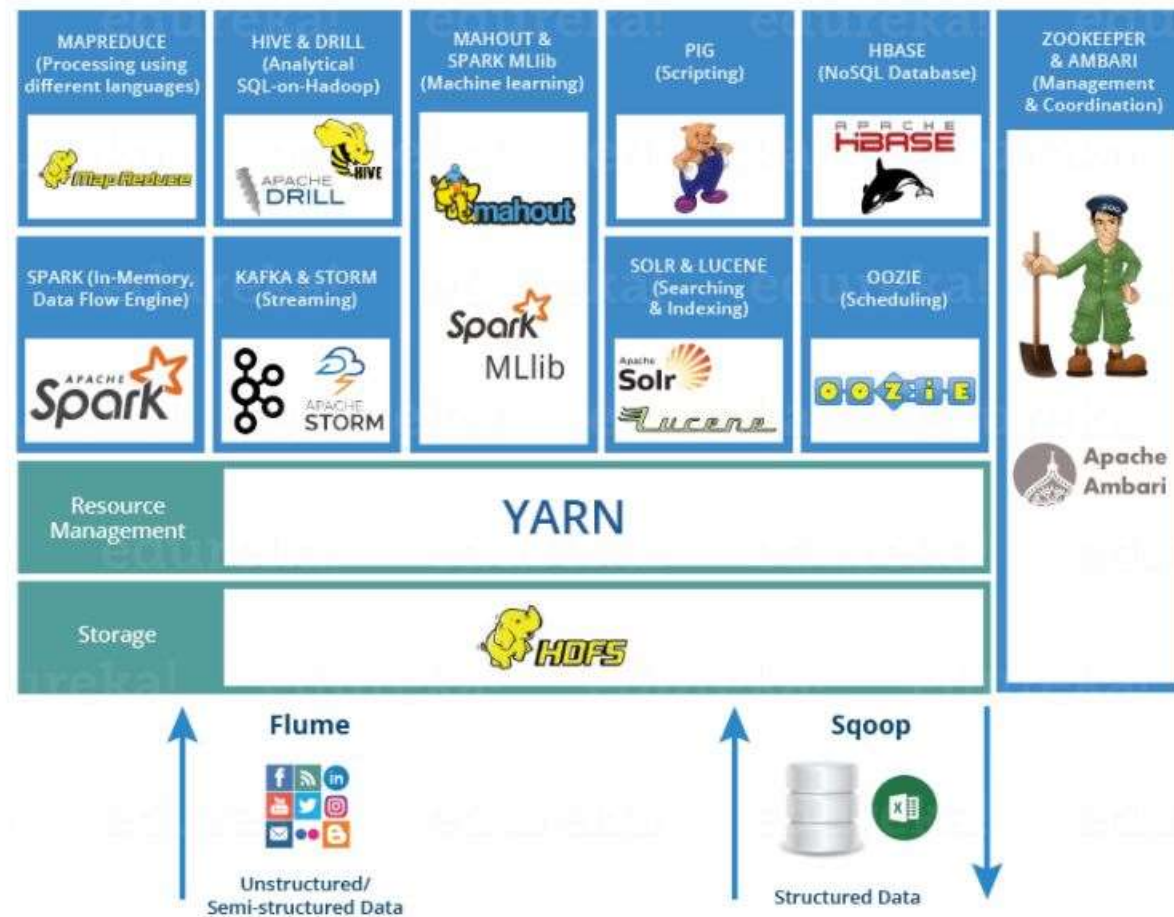


- Data Lake가 표방하는 특징들을 수용 가능한 현실적으로 거의 유일한 솔루션
- 대부분의 기업에서 솔루션으로 채택 중
- 빅데이터 분산 처리를 위한 오픈소스 기반 솔루션
- Data Lake를 구성하는 영역별 다양한 오픈소스 솔루션 제공

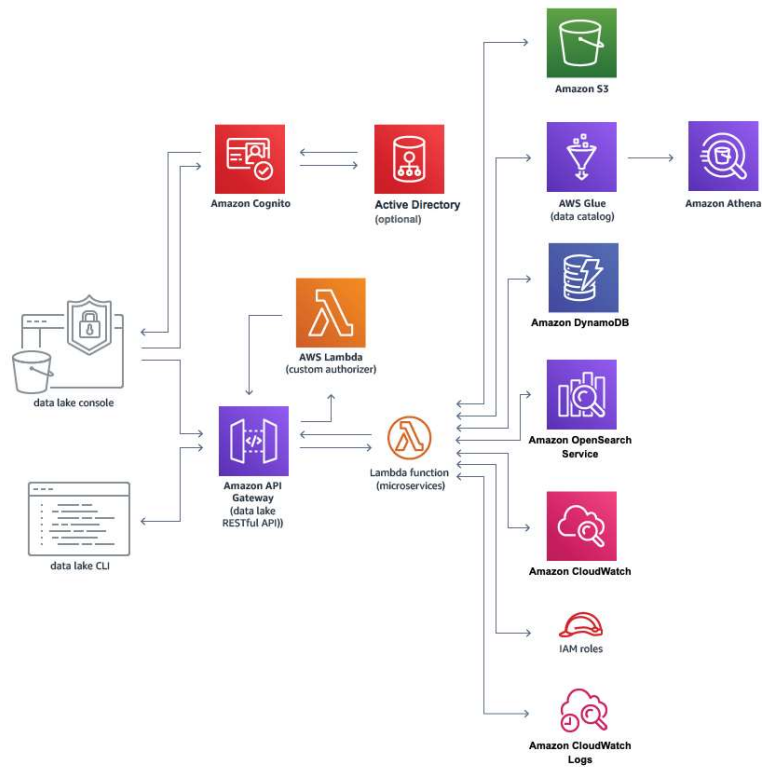


- 각 CSP별로 클라우드에서 서비스 형태로 제공

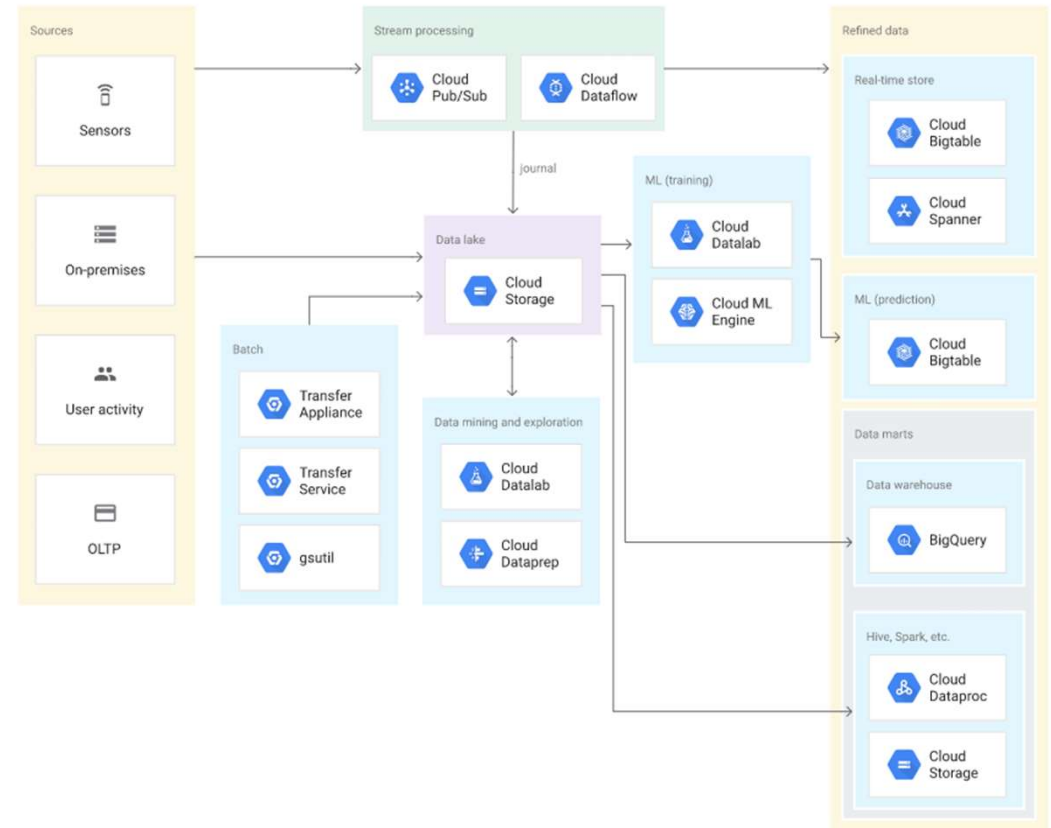
Hadoop 기반 솔루션 vs. Cloud 솔루션



Hadoop 기반 솔루션 vs. Cloud 솔루션 (Cont.)



<https://aws.amazon.com/ko/solutions/implementations/data-lake-solution/>



<https://cloud.google.com/architecture/build-a-data-lake-on-gcp?hl=ko>

Hadoop 기반 솔루션 vs. Cloud 솔루션 (Cont.)

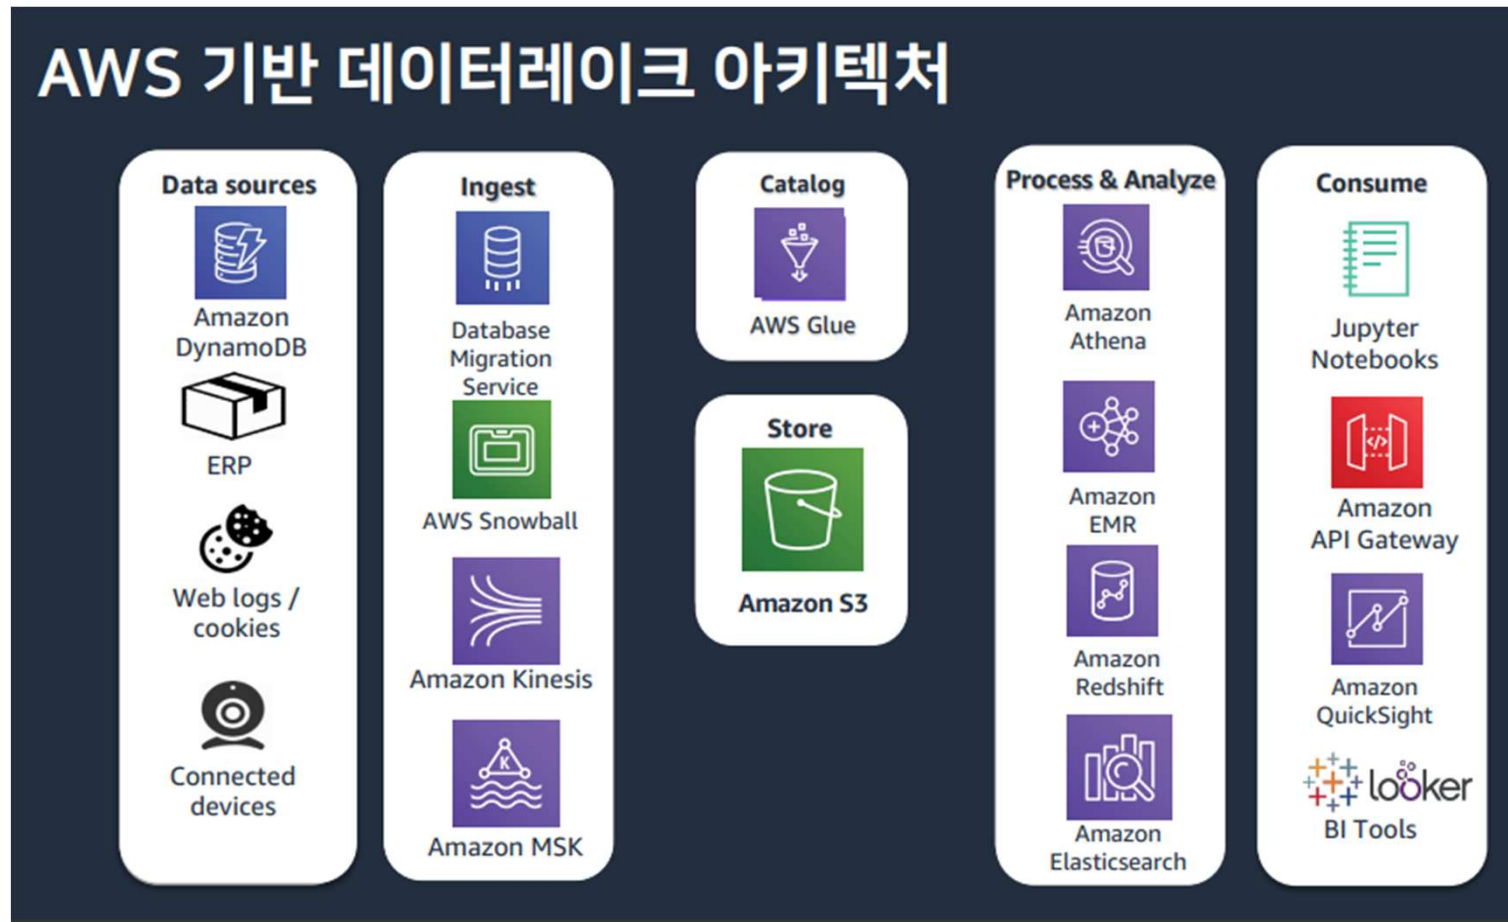
	Hadoop Solution	Cloud Solution
장점	<ul style="list-style-type: none"> • Open-Source 기반으로 솔루션 구매 비용 절감(상용 솔루션 구매 시에는 일부 증가) • 각 기업에 최적화된 형태로 커스터마이즈 • 구성원의 Hadoop에 대한 전문 역량 확보 • 특정 벤더에 Lock-In 가능성 감소 	<ul style="list-style-type: none"> • Lake 구축 위한 기간, 인력, 인프라 초기 투자 최소화 • 다양한 기술 요소별 전문 인력 확보 불필요 • 유지보수/운영 부담 최소화(솔루션 벤더에서 기술적 이슈 해결)
단점	<ul style="list-style-type: none"> • Lake 구축에 많은 기간, 인력, 인프라 초기 투자 필요 • 다양한 기술요소별 전문 개발/운영 인력 소싱 어려움 • 유지보수/운영 부담 증가(상용 솔루션 구매 시 일부 완화 가능) 	<ul style="list-style-type: none"> • 솔루션 이용량에 따른 이용 요금 부과(지속적 많은 활용 기업 비용 부담 증가) • 각 솔루션의 기능을 해당 기업에 최적화 되도록 커스터마이즈 불가) • 솔루션 벤더에 대한 의존도 높아 Lock-In 가능성 증가하고 구성원 역량 증대 제한



Building Data Lake on AWS



AWS 기반 데이터레이크 아키텍처



<https://youtu.be/eQjkwhyOOml>

Data Lake Pipeline in AWS



Data Lake Pipeline in AWS (Cont.)



Apache Spark 소개



Apache Spark



- <https://spark.apache.org/>
- Unified engine for large-scale data analytics.

Apache Spark (Cont.)



- Is an open-source, distributed processing system used for big data workloads.
- Utilizes in-memory caching, and optimized query execution for fast analytic queries against data of any size.
- Provides development APIs in Java, Scala, Python and R, and supports code reuse across multiple workloads
 - Batch processing, interactive queries, real-time analytics, machine learning, and graph processing.
- Apache Spark has become one of the most popular big data distributed processing framework with 365,000 meetup members in 2017.

Apache Spark (Cont.)



- Key features
 - Batch/streaming data
 - SQL analytics
 - Data science at scale
 - Machine learning
- Benefits of Apache Spark
 - Fast
 - Developer friendly
 - Multiple workloads

